



هدف پروژه

در این پروژه هدف این است که تصاویر مربوط به بافت‌های مواد مختلف را بر اساس ویژگی‌هایی خوشه‌بندی کنیم.

داده‌های تصویری انتخاب شده شامل مجموعه‌ای متنوع از کلاس‌های مرتبط با مواد و سطوح است. چالش اصلی در این مجموعه داده، تغییرات قابل توجه در شرایط تصویربرداری برای نمونه‌های مختلف متعلق به یک کلاس واحد است.

در نهایت، هدف ما این است که الگوریتم بتواند نمونه‌های بافتی مشابه را صرف‌نظر از این تغییرات، شناسایی کرده و در یک خوشه واحد قرار دهد.

دیتاست

این دیتاست شامل ۹ کلاس مختلف از بافت‌ها می‌باشد. هر کلاس نشان‌دهنده‌ی یک سطح خاص است.

از هر کلاس، تعدادی نمونه تصویر در مجموعه داده موجود است. هر نمونه از یک کلاس، آن بافت را تحت شرایط نوری، زوایای دید و مقیاس‌های متفاوت به تصویر می‌کشد.

فاز اول: استخراج ویژگی (Feature Extraction)

در این فاز از شما می‌خواهیم که تصاویر را پردازش کرده و ویژگی‌های مفیدی را از آنها استخراج کنید. هدف این است که بتوانید ویژگی‌هایی را استخراج کنید که هر کلاس را به خوبی نمایندگی کنند. مثلاً ویژگی‌های رنگی مانند رنگ غالب در تصویر یا ویژگی‌های بافتی مانند الگوهای تکرار شونده در تصویر یا ویژگی‌های آماری مانند میانگین، واریانس و ... ویژگی‌های ذکر شده کاملاً اختیاری هستند. در مورد ویژگی‌های مناسب برای این مساله جست و جو کنید و آن‌ها را محاسبه کنید. حداقل به استخراج ۷ ویژگی بپردازید. از مدل‌های آماده برای این کار استفاده نکنید. در نهایت ویژگی‌های استخراج شده را در یک فایل مناسب ذخیره کنید تا در مراحل بعدی مورد استفاده قرار گیرند.

فاز دوم: انتخاب ویژگی

در فاز اول، شما مجموعه‌ی بزرگی از ویژگی‌ها را استخراج کردید. با این حال، استفاده از تمام این ویژگی‌ها لزوماً به نتایج بهتر منجر نمی‌شود. بسیاری از این ویژگی‌ها ممکن است Redundant باشند؛ برای مثال، ۵ فیلتر مختلف ممکن است همگی یک نوع الگوی بافتی (مثلاً خطوط افقی) را اندازه‌گیری کنند. هدف این فاز، انتخاب یک زیرمجموعه‌ی کوچک‌تر، قدرتمندتر و متنوع‌تر از ویژگی‌ها است تا کارایی الگوریتم‌های خوشه‌بندی در فاز بعد را به حداکثر برسانیم.

۱. محاسبه ماتریس همبستگی (Correlation Matrix) شما باید افزونگی بین ویژگی‌ها را به صورت کمی اندازه‌گیری کنید. برای این کار، باید ماتریس همبستگی (Correlation Matrix) را محاسبه کنید.

پیاده‌سازی تابع محاسبه همبستگی بر عهده خودتان است. استفاده از توابع آماده مجاز نمی‌باشد. ۲. انتخاب زیرمجموعه ویژگی‌ها: بر اساس ماتریس همبستگی، شما باید برای انتخاب یک زیرمجموعه بهینه از ویژگی‌ها (حداقل ۳ ویژگی) یک استراتژی طراحی و توجیه کنید. هدف نهایی این است که مجموعه‌ی ویژگی‌های شما دارای کمترین همبستگی و بیشترین قدرت تفکیک برای خوشه‌بندی باشند.

در نهایت، ویژگی‌های انتخاب شده نهایی را در یک فایل مناسب ذخیره کنید تا در فازهای بعدی استفاده شوند.

فاز سوم: Clustering

در این فاز باید با استفاده از الگوریتم‌های KMeans، DBSCAN، Agglomerative و MeanShift، دیتاست موجود را بر اساس ویژگی‌های انتخاب شده در فاز قبلی خوشه‌بندی کنید.

برای پارامترهای هر الگوریتم باید hyperparameter tuning انجام دهید و بهترین مقادیر را انتخاب کنید. جهت مقایسه ویژگی‌های متمایز کننده هر خوشه و پیدا کردن ویژگی‌های بارز آن‌ها، یک heatmap با توجه به اعضای خوشه‌ها plot کنید.

فاز چهارم: Visualization

در این بخش، ابتدا با استفاده از کتابخانه‌های مناسب، ابعاد دیتا را کاهش داده و سپس نتیجه خوشه‌بندی را visualize کنید.

نتایج این خوشه‌بندی را در داکيومنت خود تحلیل کنید.

فاز پنجم: Evaluation

در این فاز از شما می‌خواهیم که عملکرد خوشه‌بندی انجام شده را ارزیابی کنید. معیار Rand Index را پیاده‌سازی کرده و نتایج را گزارش کنید. پیاده‌سازی این معیار بر عهده خودتان است.

معیارهای دیگری به نام Silhouette Score و Adjusted Rand Index را نیز محاسبه کنید. علت تفاوت اعداد خروجی این معیارها را تحلیل کرده و در داکيومنت خود ذکر کنید.

نتایج این فاز را در قالب یک فایل CSV ذخیره کنید.

فاز ششم: Prediction

در این فاز، داده‌هایی که به عنوان داده‌ی تست در اختیار شما قرار داده شده‌اند، باید توسط مدل خوشه‌بندی شده بررسی شوند و مشخص شود که به کدام خوشه تعلق دارند. با استفاده از ویژگی‌های انتخاب شده، از داده‌های تست ویژگی استخراج کنید.

- مدل KMeans از قبل آموزش دیده شده را روی این داده‌ها اعمال کنید و برچسب خوشه‌ی متناظر (برچسبی که بیشتر اعضای خوشه آن را دارند) را به هر نمونه اختصاص دهید.

- نتایج خوشه بندی را visualize کنید. برای هر یک از این داده های تست، ۲ داده ی دیگر از خوشه ی مرتبط با آن نیز نمایش داده شود.
- تحلیل خود را در مستندات پروژه ارائه دهید.

نکات تکمیلی

- علاوه بر سورس کد پروژه به شکل یک فایل ipynb، فایل مستندات و فایل CSV ارزیابی عملکرد نیز باید آپلود شود.
- با فرض قرارگیری دیتاست در کنار فایل ipynb، کد شما باید قابلیت اجرای مجدد داشته باشد.
- نام اعضای گروه در فایل مستندات ذکر شود و فقط یکی از اعضا پروژه را آپلود کند.
- هر گونه شباهت نامتعارف بین کد شما و کد سایر گروه ها تقلب محسوب می شود و نمره ای برای این پروژه دریافت نخواهید کرد.
- تمیز و مرتب بودن سورس کد، داکيومنت و فایل نتایج تاثیر بسزایی در نمره نهایی دارد.
- فایل ها را در قالب فایل zip و با نام شماره دانشجویی خود ذخیره و ارسال نمایید.
- در صورت وجود هرگونه سوال یا موردی می توانید با [EDabidian](#) و [Kourosh_Hsz](#) در ارتباط باشید.

موفق باشید